

Materials Benchmark v3.3: Baseline-First 全流程解读

如何先保证题目与答案正确，再做轻量结果增强

2026 年 8 月 3 日

范围：解读 materials-benchmark-review 与 materials-benchmark-repair, 并用 Ferronematic、SSH、ta-C KMC、RbC60、FK 五类 case 验证。

边界：instruction.md 是唯一 solver-visible 题面；paper.md 只供 Review/Repair；不读 solution/**, 不运行 Harbor+Codex。

核心改变：没有额外 checkpoint 也可成为 BASELINE_CORRECT；增强失败回退 Baseline；checker 成本单独决定能否发布。


当前结果：Ferronematic 与 SSH 均保留 Baseline 和 Enhanced 两层 candidate，发布最佳 Enhanced 版本；其余 case 分别为 Reauthor、Reject 和 Blocked。

1 新版为什么是 Baseline First

旧流程把完整 anti-hacking 探针和公开中间检查点绑定到 PASS，导致题目、Gold 和容差已经正确的题包仍被否决。v3.3 改为固定顺序：

1. 研究问题、方法、必要过程与论文可给参数是否正确；
2. Gold/关系是否来自同一论文条件或唯一推导；
3. 正确答案能否在合理容差内通过，明显错误是否失败；
4. checker 是否满足资源预算；
5. 最后才增加质量梯度和额外结果检查。

v3.3 baseline-first Review / Repair lifecycle



Correctness first: an enhancement failure never invalidates the reviewed Baseline.

图 1: Stage A 先产出可独立发布的 Baseline; Stage B 是可选增强, 失败时回退。

Review schema 为 materials-core-review/3.3, 同时记录 correctness_assessment、enhancement_assessment 和 checker_cost_record。Repair schema 为 materials-core-repair/2.3, 明确 BASELINE_CORRECTNESS 与 RESULT_ENHANCEMENT 两个 stage。

独立判断

PASS + BASELINE_CORRECT 已经表示题目和答案正确。RESULT_ENHANCED 只表示在此之上加入了低成本的结果关系、不变量或质量梯度; 它不是“更正确的 Gold”。

2 一个题包是什么: 选手看什么, Reviewer 看什么




图 2: 科学权威与文件可见性的单向依赖。

做题者只看 instruction.md。所以题面必须把论文研究抽成独立科学问题, 不能写“请看原文”“读取 Fig. 2”“根据 paper.md 找参数”。paper/paper.md 保存论文证据但不给做题者; tests 隐藏 Gold、精确容差和实现, 不能隐藏新的提交要求; steps.json、manifest、task 和 resources 只能镜像题面。

论文声称

论文决定研究对象、方法、固定条件、可直接使用的结果与支持关系; 论文没有报告的普通执行细节, 不会自动变成题目缺陷。

Review 执行“拿走论文测试”: 去掉 paper/后, instruction.md 仍应完整说明体系、方法边界、参数、Workflow、输出路径、schema、单位、条件组和评分对象。

3 题目正确性: 参数不是只有“给了/没给”

v3.3 把参数分为四类:

类别	含义	处理
PAPER_FIXED	论文已报告且与任务相关	题面必须保留；按 PAPER_VALUE
SOLVER_SEARCHABLE	论文未给唯一值，但可 mesh search、扫描、优化、收敛或论证	不补值、不否决；checker 不得暗中固定
TARGET_DEFINING	决定材料体系、物理状态或研究条件	缺失后无法辨认目标则失败
INDISPENSABLE_ASSET	数据集、模型、势、不可重建的固定结构快照、特定代码等输入	必须有文件、URL、运行时供给或合法替代

结构文件不是默认必需资产。论文只报告成分、晶系/空间群、晶格参数、Wyckoff 信息或构造/弛豫方法时，题面保留这些信息即可；solver 可自行建模、优化或论证合理构型，checker 以容差、关系或区间接受合法差异。只有 Gold 明确绑定一个不可从论文描述重建、且不允许等价构型的固定无定形快照、无序占位、缺陷/界面 registry、实验坐标或亚稳态构型时，才要求精确结构文件。缺少 CIF 本身不能拒绝题包。

每条参数还记录论文是否给唯一值、题面是否要求唯一值、checker 是否要求唯一值。这样可以直接识别“题面说 solver 自行收敛，但 checker 暗中只接受 $8 \times 8 \times 8$ ”的错误。

3.1 论文没写 k-grid，但论文结果事实上来自 $8 \times 8 \times 8$

只要论文没有披露这个值，Reviewer 不能把它伪称成论文参数。题面公开研究体系和论文条件，把 k-grid 留作 SOLVER_SEARCHABLE/CONVERGENCE；paper value 仍可作为同体系同条件 Gold 中心，合理实现差异由容差吸收。只有 checker 暗中要求精确 $8 \times 8 \times 8$ 选择时，才修 checker。

3.2 论文给出的步骤能否删除

论文中与做题有关的必要方法、公式、参数和 Workflow 必须保留或补齐。若删除会让中间产物消失、producer/consumer 断裂或题意歧义，就禁止删除。完整保留后如果只剩信息摘录或代数代入，回到 Q0 拒绝，不能删信息来人为制造难度。

4 两类硬拒绝与计算机可复现边界

- PURE_INFORMATION_EXTRACTION：核心评分只是从论文捞数值；
- PURE_ALGEBRAIC_COMPUTATION：题面给完公式和参数，只剩代入、算数值或直接解方程；
- 实际实验操作；
- 只有一次给定公式换算的简单实验数据分析。

题目仍须可用计算机复现。模型选择、非平凡拟合、优化、收敛、结构/轨迹分析、误差分析、候选比较和材料机理判断可以通过；不要求实验室操作。

5 答案正确性与“改条件”的明确含义

Gold 只能是 PAPER_DIRECT、UNIQUE_DERIVATION 或有文字依据的 PAPER_SUPPORTED_RELATION。每个数值 Gold 绑定体系、方法、参数组、单位与论文 locator；多组条件分别用不同 Gold，不能缩成“任选一组”。

5.1 Q1 里的“改条件”是什么

“改条件”不是换求解器、网格或收敛阈值，而是修改会改变科学目标的条件，例如材料组成、Hamiltonian、温度/压力、边界条件、尺寸或 paper 明确使用的参数组。

如果原文参数存在，直接复现任务应优先修回原文条件并保持 paper Gold 中心。只有题目明确设计为 smoke/缩小体系/趋势复现，且论文证据支持关系对新条件仍适用时，才保留改条件并评分符号、排序或趋势。改变条件后仍强求论文绝对数值，Q1/A3 失败。

独立判断

同一论文包含多组条件时，不是“必须选一组”，而是每组建立 condition signature 并检查自己的 Gold。这样扩大检查面，也避免复制、换标签和跨组混配。

容差不改变 Gold 中心。依据可为论文不确定度/有效数字、可审计数字化、独立复算、收敛、跨实现，或 Reviewer 明确写出的单位、尺度与边界理由；执行 $T - \epsilon, T, T + \epsilon$ 探针。

6 Stage A 与 Stage B 到底修什么

6.1 Stage A: BASELINE_CORRECTNESS

Stage A 补回论文必要内容、修参数冲突与派生文件、标记 solver-searchable、删除 tests 里猜测的唯一执行值、修 Gold/条件组/容差/核心输出覆盖，并验证五类基础 probe: valid、tolerance boundary、missing/malformed、non-finite/duplicate、wrong-science。

完成后必须由独立 Agent 从空白结论复审为 BASELINE_CORRECT。

6.2 Stage B: RESULT_ENHANCEMENT

Stage B 只接收已通过独立复审的 Baseline。它可以从已有最终表格重算廉价派生量，检查守恒、归一化、符号、排序、残差、跨文件关系或曲线少量代表点。Gold 占 60–80%，结果检查占 20–40%。

禁止改科学目标、paper Gold 中心、必要参数/公式/步骤；禁止固定 solver-searchable 项；禁止 checker 重跑完整 DFT/MD/训练/大规模搜索或逐帧比较完整大体积 MD 轨迹。

7 Ferronematic: 两阶段都可以独立成立

Ferronematic: correctness before optional result enhancement




图 3: 题目正确性修复与结果增强严格分开。

论文声称

论文 Eq. (13) 给出用于分支稳定性比较的自由能, Eqs. (21)–(24) 给出平均场自洽关系; 正文报告两个 $\tilde{\kappa}$ 最大值与三个 triple point。

源题只有自洽驻点方程而缺自由能, 无法判断哪个分支稳定。Stage A 补回论文方程、材料常数 and 稳定性规则; 保留 quadrature、初值、scan resolution 和求解器为 solver-searchable; 严格检查 2 个 $\tilde{\kappa}$ 组与 3 个 ω 组。Baseline 只比较两份 paper-Gold 结果, valid=1.0、wrong-science=0, 约 0.12 秒, 因此已经正确且可发布。

Stage B 才增加 mean_field_checkpoints.json, 用 η, S 重算自洽残差和 $\tilde{\kappa}$ 关系; Gold 权重 0.6, 结果检查 0.4。valid=1.0、quality-gradient=0.7、跨组交换 =0, 约 0.14 秒。增强没有改变 Gold 中心或论文条件。

8 SSH: 离线 reference, 运行时不重复大计算

旧 checker 在多个 λ 点重复对角化 1220×1220 矩阵, 且 $\ln_{\text{gap}}$ 未被独立数值覆盖。新版把昂贵 reference 生成移到题包外: 独立脚本依据 paper Eqs. (1)–(8), 在两组条件、完整 61 点 λ 网格生成 winding、 $\ln_{\text{gap}}$ 和 Lyapunov reference; 122 点离线生成约 15.7 秒。

运行时 Baseline checker 不对角化: 它检查两份 CSV 的完整网格、唯一有限行, 在 61 点计算廉价 Lyapunov 公式, 并比较每组 6 个代表点的冻结 winding/gap Gold。valid=1.0、wrong-science=0.210, 约 0.05 秒。

Enhanced 再用 0.3 权重检查论文文本支持的 re-entrant sequence 和转变附近低 gap/低 Lyapunov 关系。valid=0.925、quality-gradient=0.785、wrong-science=0.147、跨组交换 =0.224, 均与 0.6 阈值形成梯度。




图 4: 两题 *checker* 远低于成本上限; *SSH* 结果层检查形成分层。

9 另外三条路由

9.1 ta-C KMC: Reauthor

缺少可搜索执行参数本身不失败。真正问题是题面加入论文不支持的 Manhattan 邻域、逐次平均和拟合流程，并且三行手写单调数据即可通过。不能靠补参数或加严数值区间修好，必须从论文重新定义科学目标。

9.2 RbC60: Reject

论文公式和参数应完整保留；保留后核心工作只剩代入与制表，因此触发 PURE_ALGEBRAIC_COMPUTATION。答案来自论文不等于题目考查科学能力。

9.3 FK nanocluster: Blocked + Abandoned

题目与 *checker* 都不应读论文图。题面给出 FK 模型，solver 独立计算 activation energy、critical force 和 maximum spring force 三条曲线。timestep、扫描分辨率和 depinning 判据可为 SOLVER_SEARCHABLE，不是 blocker。

真正问题是数值 Gold 只在 Fig. 2/7/8，而当前 *paper.md* 只有图片占位、实际图片不可用，正文也无对应数值。因而 Gold 中心本身无法从现有原文资源审计，而不只是容差证据不足。不能要求做题者“从图中得到”，也不能用旧 grading spec 自证，故保持 BLOCKED + ABANDONED。

10 Checker 资源门槛

checker_cost_record 使用真实规模输出记录 CPU/GPU、wall time、峰值内存、读取字节、是否读完整轨迹、是否重新模拟。发布门槛：最多 32 CPU 核，或最多单 GPU；GPU 型号必须记录且能力不超过 H100；wall time 不超过 600 秒；不读完整大体积 MD 轨迹；不重新执行主科学计算。

超预算时科学 verdict 仍可为 PASS，但 *operational_status*=FAIL、*publishable*=false，路由 REPAIR_CHECKER_COST。若唯一可想到的 checkpoint 超预算，就不做 Enhancement，保留 Baseline。

Three independent decisions in v3.3



Auditable paper fidelity -- not proof that the paper itself is true.

图 5: 科学正确性、质量层级与运行成本是三个独立判定。

11 最终保证边界

实际证据

新版 validator 与测试覆盖: 可 mesh/search/converge 的缺失参数允许 Baseline; checker 暗中固定时失败; 不可替代资产不能伪装为搜索项; 无 checkpoint 的 Baseline 可 PASS; 完整轨迹、重新模拟、超过 CPU/GPU/600 秒或非真实规模成本记录不可发布; 增强失败保留源 Baseline。

独立复审后又增加事实交叉验证: Review 以 `--package` 核对真实 grading tier、权重和 tolerance\contract; Repair 以 `--verify-files` 重算变更 SHA256。Ferronematic 数值容差逐字段记录为 10^{-4} , Enhanced 权重为 Gold/result 0.6/0.4; SSH 按 observable 分别记录 Lyapunov 0.01、winding 0.1、ln\gap 0.05, 权重为 0.7/0.3。Stage B 记录真实 quality gradient, 不再虚构 fail-before/pass-after。修正后独立 Agent 复审结论为 PASS, 无剩余 P0/P1。

“至少题目和答案正确”在本流程中的准确含义是: 题面研究问题、方法、论文可给参数和必要 Workflow 定位到同一 paper.md; Gold/关系来自同一条件或唯一推导; 正确答案被合理容差接受, 明显错误失败; 所有核心输出被读取。它保证可审计的论文忠实性与评分正确性, 不证明论文自身绝对正确, 也不穷举所有未来攻击。

12 产物入口

- 规则: .cursor/skills/materials-benchmark-review、materials-benchmark-repair
- 五类 case: material_v3_question_review_processing/five_case_study
- 当前发布: material_v3_question 中的 Ferronematic 与 SSH
- 历史: MATERIAL_QUESTION_VERSION_HISTORY.md
- 状态: corpus_review_tracking.json