

材料基准题目编写

从论文 PDF 到通过独立复审的增强型 Harbor 题包

状态
提案

负责人
MatBenchGuard / qa-review

最后更新
2026 年 8 月 3 日

编写者	Codex; MatBenchGuard 项目组
复审者	独立 Review Agent; 材料科学复审者
相关文档	Authoring、Review 与 Repair Skills
范围	从论文 PDF 生成以 paper Gold 为中心的 RESULT_ENHANCED Paper2Arm 题包。

1. 摘要

本系统把材料科学题包编写视为一条有证据约束的编译流程。流程先冻结论文 PDF，使用 UniParser 生成 paper/paper.md，再建立参数、条件组、Gold 和资源台账，随后枚举多个计算科学候选问题。只有通过 Q0 准入、Gold 适用性、资源闭环和轻量增强检查点门禁的候选，才会被编译成 Harbor 题包。

核心保证是“先证明可编写，再生成题包”。成功标准不是本地 checker 变绿，而是独立 materials-benchmark-review 给出 PASS + RESULT_ENHANCED。若没有候选满足全部门槛，流程以 NO_ENHANCED_CANDIDATE 封闭失败，不把缺陷推迟给后续大规模 Repair。

2. 目标与非目标

目标	非目标
追踪论文问题、方法、参数、Gold 和完整条件签名。	不得发明论文未报告的 cutoff、mesh、timestep、model 或 solver 数值。
生成 Gold 占 60%—80%、结果检查占 20%—40%的增强题包。	checker 不得重跑 DFT/MD/training，也不得扫描完整大体积 trajectory。
以稳定文件名和科学身份表达资源，不绑定部署路径。	不负责向 Bohrium/Playground 部署资源，也不分配 Trisol ID。
只发布经过独立复审的候选，并使失败可重放。	不得创建、检查、运行、哈希或引用 solution/；不得把 Repair 当作日常收尾流程。

3. 背景与问题

material_v2_question 包含 1,878 个题包，覆盖 134 个主题；reviewed_passed 对照集包含 1,029 个题包。结构约定较强：10 个核心文件在全部题包中出现，9 个 instruction 章节在约 98%—100%的通过题包中出现，输出主要为 CSV/JSON，基础镜像也几乎统一。但资源访问方式、target policy、scoring tier、路径和 bundle mapping 存在明显历史漂移。

在 1,860 条历史最终判定中，主要硬失败信号包括 546 例 CHECKER_CORE_TASK_UNASSESSED、142 例不可用的必要输入，以及 100 例无效科学目标。当前 v3 Review 采用 Baseline-first，但这些分布仍说明：编写前必须先做 Q0 和资产闭环，生成 checker 前必须冻结 Gold，选择候选时还要确认至少存在一个真实、低成本的结果检查点。

4. 系统架构

流程把科学证据、候选选择、题包编译和独立验收分成四个可追踪层次。

Materials Benchmark Authoring Evidence-backed compilation pipeline




图 1. 有证据约束的 Authoring 编译流程。红色表示封闭失败出口，绿色表示仅发布通过独立复审的增强型候选；框内路径、状态枚举和工具名保留英文，以便直接对应实现。

核心组件

组件	职责	主要存储	失败行为
源文件冻结器 + UniParser 适配器	冻结 PDF 哈希；选择数字文本/OCR 参数；生成 paper.md；记录 token 和解析质量。	processing/source + authoring_record.json	关键公式、表格或图注缺失时标记 BLOCKED_SOURCE_PARSE。
证据映射器	提取体系、方法、四类参数、条件组、Gold 候选、资源和 Workflow 边。	题包外 authoring_record.json	核心主张缺少 locator 时不得进入候选选择。
候选门禁与选择器	论文允许时枚举至少 3 个候选；依次按 Q0、Gold、资源、Workflow 和 checkpoint 门禁。	candidate_records	全部失败时返回 NO_ENHANCED_CANDIDATE，不输出弱题包。
题包 + Gold/Checker 编译器	先写 instruction，同步 JSON/TOML/ tests，再冻结 Gold、容差、权重和隐藏 reference。	processing/candidate + evidence	条件错配、路径耦合或猜补数值时返回证据映射层。
校验器 + 独立 Review 桥接器	运行 schema、probe 和 cost 门禁；由独立 Review 决定可发布性。	validation logs + independent_review	本地通过不等于科学批准； Review 失败返回 Authoring。

5. 请求生命周期

- 1. 接收论文 PDF、稳定的 paper_id、task name 和可选资源，创建题包外的处理工作区。
- 2. 计算 PDF SHA-256；按文档类型选择 UniParser 数字文本或 OCR 模式；检查公式、表格、图注和单位。
- 3. 建立论文证据图谱；把参数分类为 PAPER_FIXED、SOLVER_SEARCHABLE、TARGET_DEFINING 或 INDISPENSABLE_ASSET。
- 4. 枚举候选并首先执行 Q0；把每个候选绑定到条件组、Gold、资源、Workflow 和 checkpoint。
- 5. 只选择具备增强可行性的候选；先写自包含 instruction，再派生 steps/manifest/resources/task。
- 6. 冻结 Gold 与容差；生成 Gold 占 60%—80%、结果检查占 20%—40%的 checker；运行 Baseline、风险匹配和真实规模成本探针。
- 7. 运行 Authoring、package 和 Harbor 静态校验及独立 Review；仅发布 PASS + RESULT_ENHANCED。

6. API 与数据合同

主数据合同：authoring_record.json

字段	类型	必需	说明
source	object	是	PDF 路径/哈希、UniParser token/flags 和 paper.md 路径；绝不记录 API key。
parse_quality	object	是	文本、公式、表格、图注完整性及 blocker。
candidate_records	array	是	每个候选的 Q0、Gold、资源、checkpoint 及 SELECTED/REJECTED 决定。
parameter_records	array	是	四类参数加 3 个唯一值布尔量，用于暴露隐藏固定。
condition_group_records + gold_records	arrays	是	完整条件签名、target 映射、policy、适用性和来源。
enhancement + probe_records	objects	是	Gold/结果权重、结果检查、5 个 Baseline probe 和至少 1 个 enhanced probe。
checker_cost_record + independent_review	objects	是	真实规模成本和最终 verdict/quality_tier/publishable；validator 运行完整 materials-core-review/3.3 artifact 和题包级一致性检查。

合同保证

authoring_record.json 是编写决策的题包外唯一事实源；Harbor 候选只保存 solver/reviewer 可用的题包文件。发布校验会运行完整 materials-core-review/3.3 validator 及其题包级 tier、权重和容差一致性检查；旧式小写 scoring_tier 不能绕过此门槛。

- instruction.md 先于所有派生视图；tests 不得新增公开要求。
- target 、 condition 、 resource 、 workflow 和 output ID 必须唯一且闭环；resource_records 、 resources.json、mapping type、bundled filename 和实际文件必须一致。
- 编写期 bundled 文件位于 resources/<filename>; instruction 只写文件名，部署 locator 后绑定。输出必须是/app/outputs 下的规范路径；paper_id 不能是路径，也不能使用保留名 solution。
- 源文件哈希、解析参数、Gold 来源、容差边界和完整的题包外 Review artifact 共同支持审计与重放；仅含 4 个字段的 Review stub 会被拒绝。

Schema 与实现：

.cursor/skills/materials-benchmark-authoring/: assets/authoring_record_template.json 与 scripts/validate_authoring_record.py。

7. 一致性、幂等与重放

并行工作按 authoring_id 隔离；系统不新增全局锁或 dispatcher。发布和 corpus_review_tracking.json 更新由人工 prompt 协调。源 PDF、证据和候选不会被静默覆盖来伪造所谓“最新版本”。

情形	预期行为	原因
再次提交同一 PDF	同一哈希复用完整解析；哈希不同则分配新的 authoring_id。	防止旧 paper.md 与新 PDF 错误配对。
解析、Gold 或资源写入失败	不输出可发布候选；记录 blocker 和最后成功阶段。	封闭失败，避免把部分证据当作完整证据。
checker probe、cost 或 Review 失败	保留候选和证据；从对应上层层修订；不得发布。	修订循环留在 Authoring 工作区内。
规则或 Harbor schema 变化	记录 Skill/Review 版本；重新运行静态校验和独立 Review。	历史 PASS 不会自动保持可发布。

8. 安全与隐私

- 只从环境读取 UNIPARSER_API_KEY；不得写入 Skill、记录、日志或题包。
- 不记录 Authorization header、预签名 URL 或可复用凭据；只保留任务 token 和非敏感解析参数。
- 论文 PDF、解析 Markdown、隐藏 Gold 和参考文件可能受许可约束；访问、分发和保留政策需要分别确认。
- 隐藏 Gold、精确容差和 checker 实现不进入 instruction；提交要求必须全部公开。
- 任意层级的 solution 路径组件都从 Authoring、Review 和 Repair 中递归排除；Harbor 脚手架必须使用 --no-solution。

9. 运行准备度

信号	SLO 或告警	负责人	发布门槛
首次 Review 增强通过率	试点目标不低于 80%；每个失败都带门禁和证据。	Authoring + 独立 Review	必需
Gold/条件/资源闭环	review-ready 阶段 100%闭环；任意悬空 ID 都会阻塞。	Authoring validator	必需
Checker 正确性探针	5 个 Baseline 加至少 1 个 enhanced probe 通过；保留分项 reward。	Checker 作者	必需
Checker 成本	最多 32 核 CPU 或单卡 H100、600 秒；真实规模；不重算主要科学过程。	Review 运行门禁	必需
UniParser 质量	关键文本/公式/表格/图注全部 PASS；否则重解析或阻塞。	源文件/解析负责人	必需

10. 备选方案

备选方案	考虑原因	未采用原因
单次 LLM：从 PDF 直接生成完整题包	速度快、调用少。	Gold、条件、资源和 checker 同时生成，错误容易自证且难以定位。
先写 Baseline，再把所有问题交给 Repair	复用现有 Repair 能力。	违背减少 Repair 的目标，而且题包生成后才暴露缺陷。
在 instruction 中硬编码/app/resources 路径	容器内约定直接。	把科学题面耦合到 Playground、Bohrium 和本地挂载细节。
在 checker 中重跑完整主要计算	表面上最难被绕过。	超出成本预算；应优先使用结果不变量和离线 reference。

11. 待决问题

1. 新题应发布到 material_v3_question，还是单独的 Authoring 生成语料？建议：先保留在独立 processing 中，等待人工决定。
2. 谁负责 resource_unique_key 到 Playground/Trisol ID 的部署映射？建议：作者声明稳定科学身份，部署者补 locator。
3. Paper2Arm schema 1.3 何时迁移到 Harbor 1.4？建议：当前保留语料 profile，并用 harbor check 发现漂移。
4. 从图中数字化得到的 Gold 需要单独规定允许工具、双人复审和不确定度记录；在此之前，无法审计的图中数值不能标为 PAPER_DIRECT。

12. 决策与后续

采用有证据约束的编译器架构，并以`.cursor/skills/materials-benchmark-authoring/`作为 M1 实现。当前版本包含 Workflow、references、solution-free 模板、authoring record、package validator 和正反合同测试。发布必须具备完整 Review 3.3 artifact、题包级一致性、规范输出路径、资源闭环，以及不超过 32 核 CPU 或单卡 H100 与 600 秒预算的 checker。下一步是用不同任务类型的真实论文做前向测试，统计首次 Review 通过率，并针对实际失败继续收紧门槛。

里程碑	交付物	退出条件
M1	Authoring Skill、schema、solution-free 脚手架、静态 validator 和中文系统设计。	Skill validator 及负向 draft、正向 review-ready 合同测试通过。
M2	使用 DFT、MD 和 model fitting 等 3—5 篇真实论文做前向测试。	每份证据台账闭环；独立 Review 失败可重放并推动门禁修订。
M3	稳定资源部署映射和独立 Review 交接。	只写文件名的 instruction 无需改题面即可在本地和 Playground 工作。
M4	批量 Authoring 试点和首次通过率指标面板。	达到增强首次通过率目标；Repair 需求下降且不引入 Gold 或资源回归。